

用于检测心房颤动的自监督内部周期感知心电图表示学习

朱向前^{a,b}、史梦楠^b、于学鑫^b、刘畅^b、连晓聪^c、费金涛^{d,e}、罗江英^{d,e}、金鑫^a、张平^{d,e}和季向阳^{b,c,*}

^aShenzhen International Graduate School, Tsinghua University, Shenzhen, 518000, China

^bDepartment of Automation, Tsinghua University, Beijing, 100084, China

^cBeijing National Research Center for Information Science and Technology (BNRist), Tsinghua University, Beijing, 100084, China

^dCardiovascular Medicine Department, Beijing Tsinghua Changgung Hospital, Beijing, 102218, China

^eSchool of Medicine, Tsinghua University, Beijing, 100084, China

文章信息

Keywords: 房颤心电图
图自监督学习深度学
习

抽象的

心房颤动是一种常见的临床心律失常，与中风和死亡率增加相关。由于注释需要专业的医学知识，利用大量心电图语料库来开发基于监督学习的准确心房颤动算法仍然具有挑战性。自监督学习 (SSL) 是广义心电图表示学习的一种有前途的方法，消除了对昂贵标签的依赖。然而，如果没有精心设计地整合与心房颤动相关的知识，现有的 SSL 方法通常无法令人满意地捕获稳健的心电图表示。在本文中，我们提出了一种内部周期感知心电图表示学习方法。考虑到心房颤动患者的心电图表现出 RR 间期的不规则性和 P 波的缺失，我们针对周期期间和周期内表征开发了特定的预训练任务，旨在学习单周期稳定的形态表征，同时保留关键的周期间特征。经过进一步微调，我们的方法在 BTCH 数据集 *i.e.* 上展示了出色的 AUC 性能，用于阵发性/持续性心房颤动检测，AUC 为 0.953/0.996。在 CinC2017 和 CPSC2021 等常用基准上，我们的方法的泛化能力和有效性得到了有竞争力的结果的证实。

一、简介

心房颤动 (AF) 是最常见的心律失常 [1]，其特征是心率模式不规则，通常以阵发性发作开始，逐渐发展为持续性形式。它经常与高风险的临床心血管并发症相关，例如中风和心力衰竭，最终导致死亡率增加 [2-4]。作为检测 AF 的常用临床工具，心电图 (ECG) 捕获反映人类心脏周期性活动的生理信号 [5-8]。心电图的基本信息在于曲线 [9] 上的形态和间隔（波之间的距离），如图 1 所示。通常，形态变化和不规则间隔通常表明相应的疾病，如 AF (*e.g.*, RR 间隔不规则和 P 波缺失)。然而，心电图的人工判读不仅依赖于专业知识，而且引入了主观性的因素。这在阵发性病例中尤其明显，在这些病例中，微妙的特征可能无法清晰可见，由于人类视觉感知的固有限制，可能会导致误解。因此，开发用于自动解释和检测心电图 AF 的高性能算法至关重要且必要。




图 1. 经典心电图曲线显示常见波形和带有测量点的关键区间。

- 手工制作的基于特征的算法依赖于从心电图波形中手动提取特征 [10-12]。一般来说，这些特征与手动或通过符号化等技术获得的 P 波或 R 波有关 [13]。随后，采用支持向量机 (SVM) 或逻辑回归 (LR) 等机器学习分类器来区分和确定房颤的存在。这些算法减轻了与手动心电图解释相关的主观性。然而，它们的性能受到手工特征构建的经验性质的阻碍，手工特征构建很难捕捉丰富而复杂的模式。

目前，相关算法大致可分为三类：

- 有监督的深度学习算法自动从 ECG 信号中提取特征 [1, 14]。自动对焦用

* Corresponding author.

E-mail address: xyji@tsinghua.edu.cn (X. Ji).

检测任务中，流行的深度学习架构包括卷积神经网络 (CNN) [15-17]、长短期记忆 (LSTM) 网络[18]、Transformers[19]和相关融合方法[20, 21]。这些算法具有在自适应高维空间中自动构建复杂特征的优点，但受到大型注释数据集的有限可用性的限制。

- 自监督学习 (SSL) 算法通过对下游任务的预训练和微调来获得相应的表示。通常，对比学习在心电图表示方面表现出巨大的潜力，涉及构建模型来评估成对心电图信号的相似性和差异，例如混合对比学习 (MCL) [22]和SimCLR[23]。此外，其他 SSL 方法，例如时空反向检测的 T-S 操作 [24]，利用一般变换辨别借口任务。这些方法利用未标记的数据[25-28]，为增强 AF 检测的性能提供了机会。然而，现有的用于 AF 检测的 SSL 方法通常涉及简单地将图像或时间序列技术转换为心电图表示，而不结合医学知识，导致结果不令人满意，特别是对于特征不太突出的阵发性心房颤动。

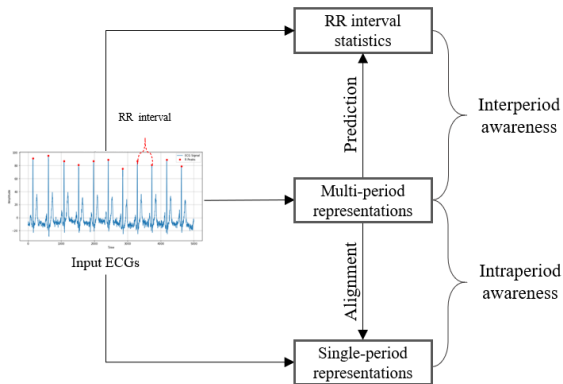


图 2.所提出方法的示意图。受医学知识的启发，AF 患者的心电图与 RR 间期的不规则性和 P 波的缺失有关，我们提出了一种自我监督的预训练方法来学习具有周期间和周期内意识的表征。

在本研究中，我们提出了一种以医学领域知识为指导的新型自监督式内周期感知心电图表示学习方法，如图2所示。鉴于房颤患者的心电图通常与RR间隔的不规则性[29, 30]和P波的缺乏有关[31-33]，我们设计了预训练任务来学习能够捕获RR间隔的周期间变异性并识别周期内缺乏P波的表示。P 波。具体来说，周期间预训练任务鼓励模型感知周期表示

这有助于识别 RR 间隔的不规则性。在周期间任务中，我们首先从多周期心电图输入中分离出 R 波位置，并独立处理它们以计算 RR 间隔，其统计数据 *i.e.*、平均值和标准差作为预测目标。然后，该任务要求多周期编码器从多周期心电图中提取表示，以准确预测这些目标。此外，周期内预训练任务增强了其表示单个周期稳定形态的能力，从而更好地捕获 P 波的缺失。在周期内任务中，多周期心电图被分解为多个单周期片段，然后与主要心搏对齐，并利用中值生成噪声较少的单周期代表性形态。随后，我们利用编码器分别提取表示，并应用对比学习来对齐同一心电图记录中的多周期和单周期稳定表示。结合所提出的任务，我们的模型可以从大量未标记的数据中学习心电图表示，不仅关注各个时期内的代表性形态，而且还关注跨多个时期的信息保存。获取 ECG 表示后，模型会在相对较小的一组标记目标数据上进行 AF 检测微调。

我们主要关注阵发性心房颤动 (AFp)，因为它对于早期治疗具有挑战性且至关重要，并对持续性心房颤动 (AFf) 进行初步测试以证明我们方法的有效性。我们的方法利用了与 AF 相关的先前医学知识，包括 RR 间隔的不规则性和 P 波的缺失。经过大量未标记数据的预训练，我们的模型从周期间和周期内的角度对心电图有了全面的了解。随后对小型注释数据集进行微调可以提高检测性能，即使在特征不明显可辨的 AFp 情况下也是如此。该方法通过从期间和期间的角度增强相关特征的可区分性来实现稳健的检测。实验结果表明，周期感知心电图表示学习优于以前的方法，证实了周期认知的重要性，包括心电图信号的周期间和周期内表示。这为大规模房颤筛查和健康监测带来了巨大希望，有可能减少医疗专业人员的工作量和医疗成本。

2 材料与方法

2.1.数据集描述

我们的私人数据集是从 2016 年 1 月至 2021 年 11 月从北京清华长庚医院 (BTCH) 收集的。心电图信号是使用 GE 医疗保健的 Marquette 心电图设备采集的。该设备记录持续时间为 10 秒、采样率为 500 Hz 的信号。这些信号由 12 条导联组成，其中 8 条导联是直接采集的 (I、II 和 V1-V6)，其余的

其中四个是通过艾因托芬定律 (III) 和戈德伯格方程 (aVR、aVL 和 aVF) 导出的：

$$\begin{aligned} \text{III} &= \text{II} - \text{I} \\ \text{aVR} &= -(\text{I} + \text{II})/2 \\ \text{aVL} &= \text{I} - \text{II}/2 \\ \text{aVF} &= \text{II} - \text{I}/2 \end{aligned} \quad (1)$$

该数据集总共包括 7,676 名患者，总共 15,695 条心电图记录。诊断标签根据 Marquette™ 12SL™ ECG 分析程序和病史的结果进行验证。最终，这些标签被专业医生标注为 Normal、AFf 和 AFp。详细信息如表 1 所示。

表1 BTCH数据集的统计信息。

	Normal	AFf	AFp
Records	6735	7980	980
Subjects	4713	2617	346
Age	50.7±17.3	73.3±10.8	70.3±10.4
Male	2723 (40.4%)	4763 (59.7%)	536 (54.7%)
P-waves absence	61 (0.9%)	7804 (97.8%)	203 (20.7%)

为了更好地评估所提出方法的有效性，我们还利用了两个与 AF 相关的公开数据集：2017 年心脏病学挑战赛 PhysioNet/Computing (CinC2017) [34] 和 2021 年第四届中国生理信号挑战赛 (CPSC2021) [35]。CinC 2017数据集由AliveCor设备采集，采样率为300 Hz，长度范围为9 s至60 s以上。完整的训练集包含 8528 个单导联心电图记录，分为四类。在我们的研究中，我们专门选择标记为“正常”和“AF”的心电信号（不区分 AFp 和 AFf）。CPSC2021 数据集是通过 12 导联动态心电图或 3 导联可穿戴心电图监测设备记录的。它提供从长期动态心电图 I 导联和 II 导联中提取的可变长度心电图记录，采样率为 200 Hz。它由 1436 条记录组成，提取自 49 名 AF 患者（包括 23 名阵发性 AF 患者）和 56 名非 AF 患者的 Holter 记录。详细信息如表 2 所示。

2.2.信号预处理

一般来说，心电信号的采集容易受到基线漂移和电力线干扰等多种形式的噪声的影响，这使得精确、鲁棒地实现房颤检测变得困难[36]。为了消除上述噪声，我们通过快速傅里叶变换 (FFT) 分析心电信号的频率特性[37]。基于 ECG 信号通常表现出小频率和低幅度的事实 [38]，我们采用 0.5 Hz 至 35 Hz 的带通滤波和中值滤波来进一步平滑和去噪。如图3所示，原始信号中的锯齿状噪声被去除，得到相对干净的心电信号。此外，对于 CinC2017 和 CPSC2021

在数据集上，我们使用滑动窗口将可变长度 ECG 记录分割成 10 秒的片段，并将它们重新采样到 500 Hz。最后，应用 Z 分数归一化以促进训练模型时快速稳定的收敛，如式 (1) 所示。(2)。

$$X_{\text{normalized}} = \frac{X - \mu}{\sigma} \quad (2)$$

2.3.基于经期意识的预训练

为了从大规模未标记心电图数据中捕获房颤检测的有效特征表示，我们提出了一种内部周期感知心电图预训练方法，如图4所示。基于房颤患者心电图表现出 RR 间期不规则和缺乏 P 波的医学先验知识，我们提出了通过探索周期间和周期内捕获单周期内稳定的形态表征和跨周期有价值的表征的方法。分别表示。

- 周期间表示学习：我们设计了一个 R 波提取器来确定 R 波在时间轴上的绝对位置。随后，通过微分运算，得到 RR 间期序列，并计算其均值和标准差作为预测目标，这在很大程度上反映了 RR 间期的不规则性。对于多周期心电信号，我们开发了一个编码器来提取特征并进一步预测上述目标。相应地，均方误差可以衡量 i_{th} 示例的损失 ℓ_i ，优化目标是最小化包含 N 示例的小批量的周期损失 $\mathcal{L}_{\text{inter}}$ ，如式 (1) 所示。(3)。

$$\begin{aligned} \ell_i &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ \mathcal{L}_{\text{inter}} &= \frac{1}{N} \sum_{i=1}^N \ell_i \end{aligned} \quad (3)$$

- 周期内表征学习：将多周期心电信号分解为多个单周期形态，然后与主搏动对齐，利用中值生成单周期表征稳定形态，可以显著降低噪声。之后，我们利用单独的编码器来处理多周期和单周期 ECG 信号，分别提取表示为 h_{multi} 和 h_{single} 的表示。使用投影头，这些表示进一步转换为潜在空间中的 z_{multi} 和 z_{single} 。来自相同心电图记录的多周期表示及其相应的单周期表示构成正例对，而源自不同心电图记录的多周期表示及其相应的单周期表示构成负例对。随后，可以通过最大化一致性来学习期间表示

表 2 所使用的三个数据集的摘要。

	BTCH	CinC2017	CPSC2021
Normal records	6735	5076	732
AF records	7980 (AFf), 980 (AFp)	758	475 (AFf), 229 (AFp)
Duration	10 s	9 s~60 s	8 s~6 h
Sample rate (Hz)	500	300	200
Lead	I,II,V1~V6 (III,avR,avL,avF)	/	I,II
Sources	GE Marquette device	AliveCor device	12-lead Holter or 3-lead wearable ECG monitoring devices




图 3.心电图信号的去噪。蓝线代表原始信号，红线代表去噪后的信号。此处仅显示 ECG 信号的 1,000 个样本（表示采样率为 500 Hz 时的 2 秒），以便更好地区分原始信号和降噪信号。

之间通过潜在空间中的对比损失。我们随机采样一小批 N 个示例，其中包含来自单周期和多周期心电图的 $2N$ 数据点。给定一个正例对，我们将小批量中的其他 $2(N - 1)$ 示例视为负例 [39]。让 $\text{sim}(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{v} / \|\mathbf{u}\| \|\mathbf{v}\|$ 表示 ℓ_2 归一化的 \mathbf{u} 和 \mathbf{v} (之间的点积，即余弦相似度)。然后，可以计算一对正样本 (i, j) [23] 的归一化温度尺度交叉熵损失 $\ell(i, j)$ ，优化目标是最小化小批量的周期内损失 $\mathcal{L}_{\text{intra}}$ ，如等式1所示。(4)

$$\ell(i, j) = -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j) / \tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k) / \tau)} \quad (4)$$

$$\mathcal{L}_{\text{intra}} = \frac{1}{2N} \sum_{k=1}^N [\ell(2k - 1, 2k) + \ell(2k, 2k - 1)]$$

其中， $\mathbb{1}_{[k \neq i]} \in \{0, 1\}$ 是当且仅当 $k \neq i$ 时评估为 1 的指示函数，而 τ 表示用于缩放相似性的温度参数。

我们方法的总损失结合了上述期间内和期间间表示学习的预训练损失，其公式为

$$\mathcal{L}_{\text{all}} = \alpha * \mathcal{L}_{\text{intra}} + (1 - \alpha) * \mathcal{L}_{\text{inter}} \quad (5)$$

其中 α 是用于平衡损失项 $\mathcal{L}_{\text{intra}}$ 和 $\mathcal{L}_{\text{inter}}$ 的超参数。

R波检测器采用Scipy库中的简单`find_peaks`函数或复杂的PanTompkins算法[40]来获取R波的位置。监督学习模型是从网络架构[41]修改而来的34层残差网络，它在心电图相关任务上实现了最先进的性能[42, 43]。在预训练阶段，前 33 层充当多周期编码器，丢弃最后一个全连接层。同时，具有扩张功能的 3 层卷积神经网络用作单周期心电图信号的编码器。预测器和投影头均由多层感知器 (MLP) 组成，用于将编码器的表示映射到指定的维度。预训练完成后，任务相关的投影头将被丢弃，编码器将被保留用于下游 AF 检测。

2.4.心房颤动检测的微调

在预训练过程中，模型的编码器逐渐吸收先验知识，从周期间和周期内的角度全面了解心电图。随后，嵌入预训练模型编码器中的知识通过权重共享转移到下游模型。如图 5 所示，ECG 信号通过编码器进行处理并产生精细的 ECG 表示。随后，心电图表示被输入分类器以获得概率

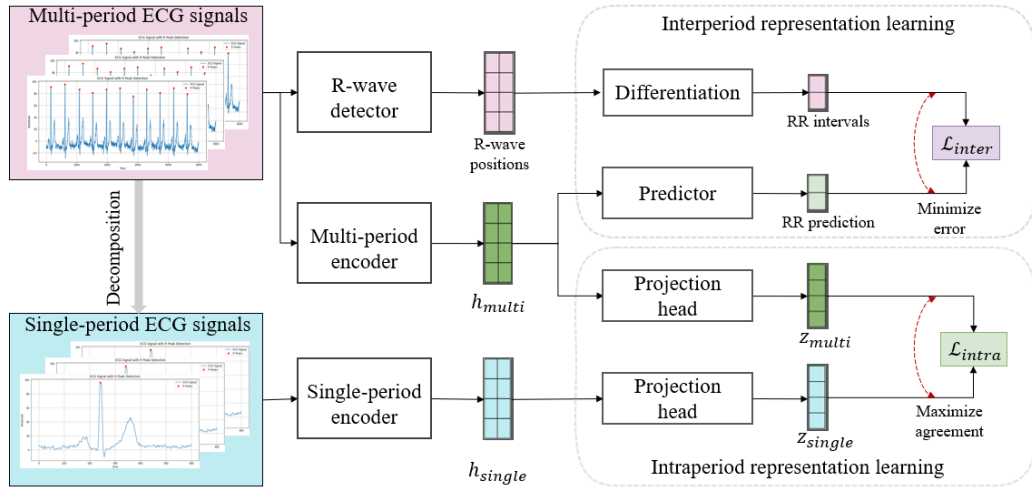


图 4.我们的自监督方法的预训练架构概述。周期间任务主要涉及预测 RR 间期信息，而周期内任务则侧重于通过本实验中的对比学习来调整单周期形态。




Fig. 5. 下游任务的自监督微调过程，特别是本实验中的心房颤动检测。

正常心律和心房颤动。具体来说，全连接层输出两个节点，一个用于正常节律，一个用于心房颤动，然后使用 Softmax 函数对它们进行归一化以产生各自的概率。考虑到相关的生理特征（例如性别和年龄）可以提供额外的信息来增强心房颤动检测性能，因此只要可用，这些特征就可以与心电图表示相结合。具体来说，生理特征与从编码器获得的心电图表示连接，然后输入全连接层进行集成和进一步分类。在实际场景中评估SSL编码器的表示能力时，需要考虑两种方法：一种是冻结编码器的权重，仅更新分类器的权重进行线性评估，另一种是更新所有参数以进行全面微调。在我们的实验中，我们专门使用多周期编码器进行这两项评估，突出了它在学习心电图表示方面的有效性和鲁棒性。值得一提的是，单周期编码器即使对于仅由单周期数据组成的数据集也很有价值，这增强了模型的可扩展性和适用性。

2.5.可视化和模型解释

人们普遍认为，可解释性对于医疗场景中的模型至关重要，以确保医疗保健专业人员和患者的接受和应用。与依赖事后解释来揭示模型决策原理的传统方法不同，我们的方法主要以算法设计和预训练任务中的医学先验知识为指导。最初，我们利用临床专业知识来分析和推断心电图信号中与 AF 相关的特征。值得注意的是，AF 可能表现为 RR 间期不规则和 P 波缺失。一方面，可视化 ECG 信号中的 RR 间期信息证实了其与 AF 的相关性，从而验证了其指导周期间表示任务的合理性。另一方面，P 波的统计分析说明了它们与 AF 的关联，使得能够将多周期信号分解为单周期代表性形态。这极大地有助于提取周期内特征，例如 P 波的缺失。可视化和统计分析强调了周期意识的重要性，并从周期间和周期内的角度增强了所提出的预训练任务的可解释性。这确保了我们的用于检测 AF 的自监督学习方法背后的机制是可以理解的，

使其更适合临床接受和应用。

3. 实验细节

3.1. 实施细节

所有模型均在配备 NVIDIA GeForce RTX 3090 GPU 的服务器上使用 Python 3.7 和 PyTorch 实现。在预训练阶段，批量大小为 16。使用 Adam 优化器，初始学习率为 0.0003。采用的调度器是 StepLR，每 3 个 epoch 的速率衰减为 0.9，保证了整个优化过程的稳定性。整个预训练过程持续 30 个 epoch，这是根据早期探索中损失下降的进展情况确定的。在微调阶段，我们使用与 Adam 优化器预训练阶段相同的初始学习率，并且调度器每个时期的速率衰减为 0.9，以加快收敛速度。采用较小的批量大小 4，标签平滑率为 0.1。在解决 AFp 检测中的类别不平衡问题时，将正样本的损失加权为 3。该策略显着提高了模型在类别分布不平衡带来挑战的场景中的性能。

3.2. 评估指标

AF 检测的主要评价指标是受试者工作特征曲线下面积 (AUC)，该面积不受样本不平衡的影响，可以有效反映检测性能。此外，还采用了一些辅助指标，包括准确性 (ACC)、敏感性 (SEN)、特异性 (SPE)、阳性预测值 (PPV) 和阴性预测值 (NPV)。它们的公式如下：

$$\begin{aligned} ACC &= \frac{TP + TN}{TP + TN + FP + FN} \\ SEN &= \frac{TP}{TP + FN} \\ SPE &= \frac{TN}{TN + FP} \\ PPV &= \frac{TP}{TP + FP} \\ NPV &= \frac{TN}{TN + FN} \end{aligned} \quad (6)$$

其中，TP 表示标记为正例且预测为正例的样本数，TN 表示标记为负例且预测为负例的样本数，FP 表示标记为负例但预测为正例的样本数，FN 表示标记为正例但预测为负例的样本数。

3.3. 基线方法

为了全面评估我们提出的 AF 检测模型，我们将其与手工特征算法和深度学习方法（包括监督和自监督方法）进行比较。每种基线方法的详细信息如下。

(a) 手工制作的基于特征的方法：这些方法通常涉及手动特征提取，然后是分类器进行检测。BOSS [13] 和 ROCKET [44] 是提取手动特征的先进技术。一些传统的机器学习算法在这种情况下充当分类器，例如 SVM 和 LR。我们从以下四种组合中选择最佳结果作为基于手工特征的方法的最终性能：BOSS + LR、BOSS + SVM、ROCKET + LR 和 ROCKET + SVM。

(b) CNN：CNN 是一种常用于心电图分类任务的人工神经网络 [41]。它由多个层组成，包括卷积层、池化层和全连接层。卷积层应用卷积运算来提取特征，例如尖锐的峰值。池化层对特征图进行下采样，以减少计算并控制过度拟合。最后，全连接层结合卷积层提取的特征进行预测。

(c) LSTM：LSTM 是一种循环神经网络架构，旨在捕获序列数据中的长期依赖性。它具有复杂的结构，包括存储单元、输入门、遗忘门以及输出门。这种架构允许 LSTM 网络选择性地记住或忘记长序列的信息，使其对于生理信号分类等任务特别有效 [45]。

(d) Transformer：Transformer 是一种依赖于自注意力机制的序列到序列模型，它允许模型在生成输出时权衡输入序列不同部分的重要性。Transformer 的编码器用于心电图分类，展示了它们在捕获心电图信号中的远程依赖性方面的潜力 [46]。

(e) SimCLR [23]：SimCLR 是一个用于表示对比学习的简单框架。它通过两种类型的数据增强形成正样本对，并通过对比损失最大化这些对的一致性。这种学习相应表示的预训练方法对于增强预测任务起着至关重要的作用。

(f) MCL [22]：MCL 是一种无监督对比学习框架，是从标签平滑的角度出发的。这种创新方法利用独特的对比损失函数，无缝地结合了数据增强策略。该策略涉及通过将两个数据样本与混合组件混合来创建新样本。主要目标是预测混合分量，该分量用作损失函数中的软目标。

(g) T-S [24]：T-S 是一种简单而有效的心电图表示学习自监督方法。受心电图信号时间和空间特征的启发，原始信号被水平翻转（时间反转）、垂直翻转（空间反转）以及水平和垂直翻转（时空反转）。然后通过对包括原始信号在内的四种类型的信号进行分类来完成学习。

为了确保 AF 检测性能的公平比较，自监督学习模型采用相同的网络架构。为了提高性能，所有深度学习模型都通过在分类器之前连接基本生理指标（性别、年龄）来合并它们。由于心电图曲线上缺乏明显的特征，这些模型主要用于 AFp 检测这一具有挑战性的任务。

3.4.消融研究

为了彻底验证所提出的自监督学习策略的有效性，我们进行了消融研究，通过比较以下变体来研究周期内和周期间的表征。

- 周期间表征检测：将总损失 \mathcal{L}_{all} 中的 α 设置为0，导致模型仅关注与AF相关的周期间RR间隔信息。通过专门考虑各个时期之间更广泛的时间背景，该模型旨在增强对超越各个时期的模式的理解。
- 周期内表示检测：此任务需要将总损失 \mathcal{L}_{all} 中的 α 设置为1，仅强调单个周期内的信息。通过对比学习，主要目标是将多周期心电图信号与各个周期内的稳定形态对齐。
- 周期内表示检测：总损失 \mathcal{L}_{all} 中的 α 设置为0.5，同时考虑周期间和周期内信息。综合目标是将多周期心电图信号与单周期稳定形态对齐，同时保留周期间差异。这种方法力求达到平衡，承认时期内和时期间表征的重要性，旨在获得能够捕捉潜在生理模式复杂性的整体表征。

3.5.可扩展性实验

考虑到标准12导联心电图，直接获得8个导联，其余4个导联可以使用简单的公式计算。因此，我们的主要实验集中在8导联ECG信号上，以减少计算量并加快训练速度。随后，我们广泛进行了涉及单引线和双引线配置的实验，以验证我们的方法在可穿戴设备和大规模健康监测计划中的潜在应用。此外，考虑到不同的数据量，我们深入探讨了自监督学习方法与监督学习相比的有效性。这种比较分析旨在深入了解我们的方法在不同数据集上的可扩展性和稳健性，揭示其在各种医疗保健场景中的实际应用潜力。

4. 结果

4.1.基线方法的结果

表3展示了基线方法和我们在 BTCH 数据集上用于 AFp 检测的自监督帧内周期感知心电图表示学习的比较结果。尽管特征提取和分类方法存在差异，但手工制作的特征算法往往表现出较低的 AUC 和灵敏度。尽管 Transformer 和 LSTM 模型擅长处理一般序列数据，但它们的有效性在多导联和多周期 ECG 信号的背景下受到限制，在这些信号中它们的性能略优于手工制作的特征。CNN 擅长识别心电图信号的形态变化，从而具有具有竞争力的 AUC 评分和高灵敏度的卓越疾病检测能力。这些监督学习方法的性能受到标记数据的限制，难以实现进一步的改进。

此外，我们将其与现有流行的自监督方法进行比较，包括 SimCLR [23]、MCL [22] 和 T-S [24] 方法。为了客观地评价模型的性能，SimCLR的最终结果是以下两对增强方法得出的平均结果：（1）添加噪声和随机排列；（2）水平翻转和垂直翻转。完成预训练任务后，我们加载预训练的模型权重并对 AF 检测进行全面微调。如表3所示，自监督学习方法通常优于监督学习方法，因为自监督学习利用未标记的数据来挖掘更多信息。此外，所提出的帧内周期感知心电图表示方法优于现有的自监督学习方法，取得了出色的结果，AUC 为 0.953，灵敏度为 0.854。SimCLR 和 T-S 在利用水平翻转和垂直翻转变换时表现出改进。MCL 采用具有超参数调整相似性的两个数据样本的混合，这也产生了良好的结果。这意味着在对这些转换进行预训练之后，模型能够捕获有利于下游 AF 检测的特征。

此外，我们在预训练后对模型的自动对焦检测能力进行线性评估。如图7所示，尽管所有方法的性能都不符合完全微调的性能，但我们的方法在线性评估方面优于以前的自监督方法，并且在心电信号的预训练任务中表现出显著的优势，这进一步验证了我们的周期内和周期间表示的有效性。

为了验证我们的自我监督学习方法的有效性，我们在公开数据集上进行了实验，特别是CPSC2021和CinC 2017，如表4所示。CPSC2021数据集区分阵发性心房颤动（AFp）和持续性心房颤动（AFf），而CinC2017数据集不区分心房颤动（AF）的类型。上

表 3 我们的模型与其他模型在 BTCH 数据集上检测阵发性心房颤动的比较。表中的粗体字母表示该列中的最佳结果，而下划线表示第二好的结果。（其他表也是如此。）

	Methods	AUC	ACC	SEN	SPE	PPV	NPV
Supervised learning	Handcrafted [13]	0.805	0.875	0.030	0.999	0.857	0.875
	LSTM [45]	0.766	0.771	0.282	0.846	0.220	0.884
	Transformer [46]	0.916	0.878	0.768	0.893	0.503	0.965
	CNN [41]	0.912	0.804	0.883	0.792	0.396	0.978
Self-supervised learning	MCL [22]	<u>0.946</u>	0.907	0.821	0.919	0.586	0.973
	SimCLR [23]	0.927	0.898	0.753	0.921	0.600	0.960
	T-S [24]	0.931	0.899	0.767	0.919	0.594	0.962
Ablation study	Interperiod	0.939	0.921	0.796	<u>0.940</u>	<u>0.672</u>	0.968
	Intraperiod	0.945	0.889	0.767	<u>0.907</u>	<u>0.560</u>	0.962
	Inter-Intraperiod (ours)	0.953	<u>0.912</u>	<u>0.854</u>	0.921	0.624	<u>0.976</u>

表 4 在两个公开数据集上的 AUC 结果与当前的自监督学习方法进行了比较。CPSC2021进一步区分了阵发性心房颤动（A Fp）和持续性心房颤动（AFf），而CinC2017没有对心房颤动（AF）进行进一步区分。

Methods	CPSC2021(AFp)	CPSC2021(AFf)	CinC2017(AF)
MCL[22]	<u>0.931</u>	0.983	0.976
SimCLR [23]	<u>0.912</u>	0.978	0.964
T-S [24]	0.925	<u>0.987</u>	<u>0.981</u>
Inter-Intraperiod(ours)	0.946	0.999	0.991

CPSC2021 数据集，我们提出的方法在阵发性和持续性心房颤动方面均优于现有的自我监督学习方法。持续性心房颤动的检测性能优于阵发性心房颤动，因为持续性心房颤动表现出更明显的特征。即使在不区分心房颤动类型的 CinC2017 数据集上，我们的方法也表现出出色的检测性能，证实了有效性和泛化能力。

4.2.消融研究结果

表 3 和图 6 显示了 BTCH 数据集上 AFp 检测的消融研究结果。结果表明，在 AUC 中，期内表征表现出相对优越的期间表征。这种差异可能是由于周期间任务相对简单的性质引起的，该任务仅集中于 RR 间隔信息。相比之下，周期内表示方法捕获更广泛的形态信息，在心电图信号的整个稳定期内提供更丰富的背景。同时，当将期间内和期间间表示结合起来时，性能最佳，这表明两种表示都捕获了互补的特征。




图 6. 消融研究的受试者工作特征 (ROC) 曲线。

4.3.可扩展性实验的结果

我们使用单导联（导联 I）和双导联（导联 I、II）配置进行实验，旨在探索所提出的方法在可穿戴设备和减少数据的大规模健康监测中的潜在应用

购置成本。如表 5 所示，我们的自监督学习方法在单导联心电图上的应用显示出与纯监督学习相比的改进。此外，它还表明，改进

表 5 单导联和双导联心电图监督模型与我们的期间（微调模型）之间的比较结果。

		AUC	ACC	SEN	SPE	PPV	NPV
Supervised model	I	0.894	0.810	0.845	0.804	0.399	0.971
	I+II	0.899	0.883	0.699	0.912	0.550	0.952
Inter-Intraperiod	I	0.916	0.858	0.835	0.861	0.480	0.971
	I+II	0.918	0.890	0.767	0.909	0.564	0.962

表 6 从头开始训练的模型的 AUC 以及使用不同数量训练数据的周期内表示的自监督学习模型的 AUC。

# of training records	100	200	500	1000	2000	5000
From scratch (AUC)	0.534	0.564	0.620	0.720	0.844	0.925
Inter-Intraperiod (AUC)	0.712	0.727	0.772	0.798	0.858	0.946




图 7. 其他自监督学习与我们的方法之间的 AUC 比较。蓝色条代表线性评估，而绿色条代表完全微调的结果。

使用我们的自我监督学习的性能超过了添加额外导联的性能（AUC, 0.916 vs. 0.899），证实了使用更少的导联和自我监督学习进行 AF 检测的功效和有效性。

此外，我们还比较了自监督学习方法和在不同数据量下从头开始训练的监督学习方法的性能。如表 6 所示，我们的自监督方法通常优于在不同数据量上从头开始训练的监督学习方法。值得注意的是，在处理有限的标记数据时，我们的自监督学习方法的性能改进尤其明显。

4.4. 可视化和模型解释

为了增强我们用于 AF 检测的方法的可解释性，我们对周期间和周期内的表示进行了一系列相应的可视化和分析。在跨期表示的背景下，图 8 说明了基于 BT CH 数据集的 RR 间隔的平均值和标准差的分布。我们可以

观察正常和 AFf 之间的明显差异，而与 AFp 相关的差异相对微妙，这为 AFp 检测带来了更大的挑战和价值。对于周期内表示，我们对 P 波特征的缺失进行了统计分析。研究结果表明，AFf 在 97.8% 的病例中没有 P 波，而 AFp 仅在 20.7% 的病例中没有 P 波。在正常个体中，P 波缺失的情况非常罕见，大约为 0.9%。这些从时期间和时期内表示的角度证实了用于指导预训练任务的先验知识的合理性。




图 8. RR 间隔的分布。横轴表示平均值，纵轴表示标准差。椭圆轮廓包围了相应类别 80% 的点。

5. 讨论

我们的自我监督学习方法从周期间和周期内的角度进行心电图表示。

采用自监督预训练从海量未标记数据中获取心电图表示，克服了数据标注耗时耗力的挑战。预训练任务的设计以医学专业知识为指导，认识到 AF 患者经常表现出不规则的 RR 间隔和心电图信号中缺乏 P 波，分别对应于周期间和周期内特征。此外，利用少量注释数据进行微调，以增强下游 AF 检测的性能。

随后，模型在相对较小的标记数据集上进行微调，主要关注 AFp 检测。如图6和表3所示，期间和期间内的预训练任务都做出了很大的贡献。周期间和周期内特征的合并表示显著增强了 AF 检测，超越了现有自我监督学习方法的性能。此外，部分导联心电图实验证实了使用较少导联和自监督学习进行 AF 检测的有效性。这些为可穿戴设备和大规模健康检查提供了潜在的支持。表 6 显示，与从头开始训练相比，我们的自监督学习方法提高了性能，特别是在数据有限的场景中。

在未来的工作中，我们计划基于医学先验知识探索其他心血管疾病在心电图数据中的表示，指导预训练任务以提高特定情况的检测能力。此外，我们的目标是从可穿戴设备收集心电图数据，并评估其检测房颤的有效性，特别是在早期筛查和大规模健康监测的背景下，以期简化医疗程序。

六、结论

在这项研究中，我们提出了一种自监督的帧内周期感知心电图表示学习方法，专门用于检测心房颤动 (AF)。我们的方法包括两个关键阶段：对大型未标记数据集进行预训练以学习稳健的心电图表示，并对相对较小的标记数据集进行微调以进行 AF 检测。在医学先验知识的指导下，我们设计了捕获心电图信号周期性特征的预训练任务。这使得我们的模型能够从周期间和周期内的角度全面理解心电图模式。在微调阶段，这些学习到的表示被进一步细化，以增强它们对 AF 检测的适用性。我们的实验结果表明，所提出的方法在 AF 检测性能方面优于现有的自监督方法。消融研究证实了结合跨时期和跨时期表征学习的重要性和有效性。此外，利用医学知识不仅可以提高模型性能，还可以增强可解释性，使我们的模型更容易被临床接受。此外，我们评估了我们的模型在部分导联心电图信号上的可扩展性，确认

其在少量引线配置方面的优势，有望降低数据收集成本。这表明其在可穿戴设备和大规模健康监测系统中的潜在应用，为通过有效的房颤检测降低医疗成本提供了前景。总之，我们的方法在自监督心电图表示学习方面取得了重大进展，有效地将医学见解与先进的机器学习技术相结合，为 AF 检测提供了强大且可行的解决方案。

参考

- [1] B. Król-Józaga, 使用卷积神经网络对心电图信号的二维表示进行心房颤动检测, 生物医学信号处理和控制 74 (2022) 103470.
- [2] C. Marini, F. De Santis, S. Sacco, T. Russo, L. Olivieri, R. Totaro, A. Caroli, 心房颤动对缺血性中风发病率和结果的影响: 基于人群的研究结果, Stroke 36 (2005) 1115–1119.
- [3] A. Ott, M. M. Breteler, M. C. de Bruyne, F. van Harskamp, D. E. Grobbee, A. Hofman, 基于人群的研究中的心房颤动和痴呆: 鹿特丹研究, Stroke 28 (1997) 316–321.
- [4] T. J. Wang, M. G. Larson, D. Levy, R. S. Vasan, E. P. Leip, P. A. Wolf, R. B. D’Agostino, J. M. Murabito, W. B. Kannel, E. J. Benjamin, 房颤和充血性心力衰竭的时间关系及其对死亡率的影响: 弗雷明汉心脏研究, 循环 107 (2003) 2920–2925.
- [5] Y. Hagiwara, H. Fujita, S. L. Oh, J. H. Tan, R. S. Tan, E. J. Ciaccio, U. R. Acharya, 基于心电图信号的房颤计算机辅助诊断: 综述, 信息科学 467 (2018) 99–114.
- [6] T. A. R. Lankveld, S. Zeemering, H. J. G. M. Crijns, U. Schotten, 心电图作为确定心房颤动复杂性的工具, Heart 100 (2014) 1077–1084.
- [7] R. G. Tieleman, Y. Plantinga, D. Rinkes, G. L. Bartels, J. L. Posma, R. Cator, C. Hofman, R. P. Houben, 房颤筛查新型诊断设备的验证和临床应用, Eurpace 16 (2014) 1291–1295.
- [8] H. Serhal, N. Abdallah, J.-M. Marion, P. Chauvet, M. Oueidat, A. Humeau-Heurtier, 使用小波和人工智能对心电图进行房颤预测、检测和分类的概述, 生物学和医学计算机 142 (2022) 105168.
- [9] S. A. Jones, 心电图注释: 解释和管理指南, FA Davis, 2021.
- [10] R. Coe, P. Carvalho, J. Henriques, M. Antunes, M. Harris, J. Habetha, 使用基于模型的心电图分析检测心房颤动, 见: 2008 年第 19 届模式识别国际会议, IEEE, 2008. URL: <http://dx.doi.org/10.1109/icpr.2008.4761755>.
- [11] B. Logan, J. Healey, 长期远程监护系统中心房颤动的稳健检测, 见: 心脏病学计算机, 2005 年, IEEE, 2005 年. URL: <http://dx.doi.org/10.1109/cic.2005.1588177>.
- [12] K. Tateno, L. Glass, 使用 rr 和 deltarr 间隔的变异系数和密度直方图自动检测心房颤动, 医学和生物工程与计算 39 (2001) 664–671.
- [13] P. Schäfer, 向量空间中的 Bag-of-sfa-symbols (boss vs) (2015).
- [14] M. Kulin, T. Kazaz, I. Moerman, E. De Poorter, 从频谱数据进行端到端学习: 频谱监测应用中无线信号识别的深度学习, IEEE Access 6 (2018) 18484–18501.
- [15] Z. I. Attia, P. A. Noseworthy, F. Lopez-Jimenez, S. J. Asirvatham, A. J. Deshmukh, B. J. Gersh, R. E. Carter, X. Yao, A. A. Rabinstein, B. J. Erickson, S. Kapa, P. A. Friedman, 一种用于识别心房患者的人工智能心电图算法颤动

窦性心律期间：结果预测的回顾性分析，《柳叶刀》394 (2019) 861–867。[16] A. Y. Hannun, P. Rajpurkar, M. Haghpahani, G. H. Tison, C. Bourn, M. P. Turakhia, A. Y. Ng, 使用深度神经网络在动态心电图中进行心脏病专家级心律失常检测和分类, *Nature Medicine* 25 (2019) 65–69。[17] U. Erdenebayar, H. Kim, J.-U. Park, D. Kang, K.-J. Lee, 使用短期正常心电图信号基于卷积神经网络自动预测心房颤动, 《韩国医学杂志》34 (2019)。[18] Y. Xia, N. Wulan, K. Wang, H. Zhu, 通过深度卷积神经网络检测心房颤动, *计算机生物学与医学* 93 (2018) 84–92。[19] G. Yan, S. Liang, Y. Zhang, F. Liu, 融合时间特征的变压器模型用于心电图心跳分类, 见: 2019 IEEE 国际生物信息学和生物医学会议 (BIBM), IEEE, 2019。URL: <http://dx.doi.org/10.1109/bibm47256.2019.8983326>。doi: 10.1109/bibm47256.2019.8983326。[20] J. Wang, 基于卷积和改进的 elman 神经网络的心房颤动信号分类的深度学习方法, *Future Generation Computer Systems* 102 (2020) 670–679。[21] M. Limam, F. Precioso, 基于卷积循环神经网络的房颤检测和心电图分类, $\frac{1}{2}$, 见: 2017 年心脏病学计算会议 (CinC), CinC2017, 心脏病学计算, 2017。URL: <http://dx.doi.org/10.22489/cinc.2017.171-325>。土井: 10. 22489/cinc.2017.171-325。[22] K. Wickstrøm, M. Kampffmeyer, K. O. Mikalsen, R. Jensen, 混合对比学习: 时间序列的自监督表示学习, *模式识别快报* 155 (2022) 54–61。[23] T. Chen, S. Kornblith, M. Norouzi, G. Hinton, 视觉表示对比学习的简单框架, 见: 国际机器学习会议, PMLR, 2020 年, 第 1597–1607 页。[24] W. Zhang, S. Geng, S. Hong, 通过操纵时空反向检测的简单自监督心电表示学习方法, *生物医学信号处理和控制* 79 (2023) 104194。[25] S. Morandé, 利用未标记数据中的自我监督在人工智能模型中进行有效的世界表示学习 (2023)。[26] A. Chowdhury, J. Rosenthal, J. Waring, R. Umeton, 将自我监督学习应用于医学: 对最先进技术和医疗实施的回顾, *信息学* 8 (2021) 59。[27] K. Ohri, M. Kumar, 使用深度神经网络进行自我监督图像识别的评论, 基于知识的系统 224 (2021) 107090。[28] T. Q. Vinh, H. Byeon, 自我监督学习对锯齿的承诺, *国际高级计算机科学与应用杂志* 14 (2023)。[29] D. 杜维尼, J.-M. GASPOZ, V. Pichot, F. Roche, R. Brion, A. Antoniadis, J.-C. BARTHÉLÉMY, 使用心率间隔小波变换自动检测心房颤动的高精度, *起搏和临床电生理学* 25 (2002) 457–462。[30] S. Sarkar, D. Ritscher, R. Mehra, 慢性植入式房性心律失常监测仪的检测器, *IEEE Transactions on Biomedical Engineering* 55 (2008) 1219–1224。[31] L. Clavier, J. M. Boucher, R. Lepage, J. J. Blanc, J. C. Cornily, 容易发生心房颤动的患者的自动 p 波分析, *医学和生物工程与计算* 40 (2002) 63–71。[32] I. Dotsinsky, 用于发现某些节律异常的心房波检测算法, *生理测量* 28 (2007) 595。[33] J. R. Ehrlich, K. Schadow, K. Steul, G. 张, C. Israel, S. Hohn-lose, 通过 p 波信号平均心电图预测体外复律后心房颤动的早期复发, *心脏病学临床研究* 92 (2003) 540–546。[34] G. Clifford, C. Liu, B. Moody, L.-w. Lehman, I. Silva, Q. Li, A. Johnson, R. Mark, Af 根据短单导联心电图记录进行分类: 2017 年心脏病学挑战中的生理网络计算, 见: 2017 年心脏病学计算会议 (CinC), CinC2017, 计算

心脏病学, 2017 年。网址: <http://dx.doi.org/10.22489/cinc.2017.065-469>。doi: 10.22489/cinc.2017.065-469。[35] X. Wang, C. Ma, X. Zhang, H. Gau, G. D. Clifford, C. Liu, 动态心电图记录中的阵发性房颤事件检测: 2021 年第四届中国生理信号挑战赛, *Proc. PhysioNet* (2021) 1–83。[36] A. N. Uwaechia, D. A. Ramli, 关于心电图信号作为人类身份验证新生物识别方式的综合调查: 最新进展和未来挑战, *IEEE Access* 9 (2021) 97760–97802。[37] K. Aditya, C.-H. H. Chu, 基于快速傅里叶变换 (fft) 的离散小波变换的快速体系结构和算法, 见: H. H. Szu (Ed.), *小波应用 II*, SPIE, 1995。URL: <http://dx.doi.org/10.1117/12.205461>。doi: 10.1117/12.205461。[38] H. Li, Z. Lin, Z. An, S. Zuo, W. Zhu, Z. Zhu, Y. Mu, L. Cao, J. D. Prades García, 利用贝叶斯优化改进的双向长短期记忆网络自动心电图检测和分类, *生物医学信号处理与控制* 73 (2022) 103424。[39] T. Chen, Y. Sun, Y. Shi, L. Hong, On 基于神经网络的协同过滤的采样策略, 见: 第 23 届 ACM SIGKDD 国际知识发现和数据挖掘会议论文集, 2017 年。[40] J. Pan, W. J. Tompkins, 实时 qrs 检测算法, *IEEE Transactions on Biomedical Engineering* BME-32 (1985) 230–236。[41] S. Xie, R. Girshick, P. Dollar, Z. Tu, K. He, 深度神经网络的聚合残差变换, 见: 2017 年 IEEE 计算机视觉和模式识别会议 (CVPR), IEEE, 2017。URL: <http://dx.doi.org/10.1109/cvpr.2017.634>。doi: 10.1109/cvpr.2017.634。[42] S. Hong, Y. Zhou, M. Wu, J. Shang, Q. Wang, H. Li, J. Xie, 结合深度神经网络和工程特征进行心电图记录心律失常检测, *生理测量* 40 (2019) 054009。[43] S. Hong, Y. Xu, A. Khare, S. Priambada, K. Maher, A. Aljiffry, J. Sun, A. Tumanov, Holmes: 用于重症监护病房深度学习模型的健康在线模型集成, 见: 第 26 届 ACM SIGKDD 国际知识发现和数据挖掘会议记录, *KDD '20*, ACM, 2020。网址: <http://dx.doi.org/10.1145/3394486.3403212>。号码: 10.1145/3394486.3403212。[44] A. Dempster, F. Petitjean, G. I. Webb, Rocket: 使用随机卷积核进行异常快速且准确的时间序列分类, *数据挖掘和知识发现* 34 (2020) 1454–1495。[45] 施晓, 陈志, 王红, D.-Y. 杨 W.-K. 黄, W.-c. Woo, 卷积 lstm 网络: 一种用于降水临近预报的机器学习方法, *神经信息处理系统的进展* 28 (2015)。[46] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, 。 Kaiser, I. Polosukhin, 注意力就是你所需要的, *神经信息处理系统的进展* 30 (2017)。